



Programa Certified AI-LLM Integration Engineer

\Curso de Fundamentos de LLMs y APIs

Aplicación de Sistemas Distribuidos y Contenedores en Infraestructura Escalable para
LLMs

www.bsginstitute.com

Andrés Felipe Rojas Parra

- Ingeniero electrónico con mas de 23 años de experiencia
- PGP Artificial Intelligence & Machine Learning at Texas University – Austin, TX
- Master en Inteligencia Artificial y Big Data – IEBSchool
- Estudiante de PGP en Cloud Computing at Texas University - Austin, TX
- Texas Executive Education Program – McCombs School of Business – Decision Science and AI Immersion Program
- Especialización en MLOps de la Universidad de Duke



arojaspa@outlook.com



@arojaspa



<https://www.linkedin.com/in/arojaspa/>



+573005906373



Fundamentos de Arquitectura LLM

Capítulo 1 — Sesión 1: Conceptos Fundamentales

Tema 1: Introducción a Arquitecturas LLM

Tema 2: Tipos de Modelos y Servicios

Tema 3: Consideraciones de Costos

Agenda de la Sesión

1

Introducción a Arquitecturas LLM

~60 min

- Bienvenida e introducción
- Origen y evolución de los LLM
- Relevancia en el ecosistema IA
- Impacto real en la industria

2

Tipos de Modelos y Servicios

~60 min

- Decoder, Encoder, Encoder-Decoder
- Cloud vs On-premise
- Casos de uso LATAM
- Comparativa de proveedores

3

Consideraciones de Costos

~60 min


- Evaluación de proveedores
- Costos a corto y largo plazo
- ROI y análisis de riesgo
- Demo: calculadora de costos

TEMA 1

Introducción a Arquitecturas LLM

Del perceptrón al GPT-4 en 7 décadas de historia

Evolución de los LLM



🔑 El paper "Attention is All You Need" (Google, 2017) es el punto de inflexión: introduce la arquitectura Transformer que sustenta todos los LLM modernos.

¿Qué hay dentro de un LLM?



GPT-4 tiene estimados ~1.8 BILLONES de parámetros organizados en cientos de capas como la mostrada arriba. Cada parámetro es un número que el modelo aprendió de trillones de palabras.

Impacto Real en la Industria



Sector Financiero

- Anti-fraude en tiempo real
- Análisis de riesgo crediticio
- Atención 24/7 automatizada
- KYC documental automático

↓40%
**costos
operativos**



Salud

- Resumen de historias clínicas
- Codificación ICD automática
- Asistente de diagnóstico
- Triage inteligente

↑35%
**eficiencia
médica**



Sector Público

- Chatbots de atención ciudadana
- Procesamiento de trámites
- Análisis de políticas públicas
- Transparencia gubernamental

×3
**más
trámites/dí
a**



Legal & Compliance

- Revisión de contratos
- Due diligence automatizado
- Monitoreo regulatorio
- Redacción de documentos

↓60%
**tiempo
revisión**

TEMA 2

Tipos de Modelos y Servicios LLM

Cloud, on-premise, open source — ¿Cuál es el correcto para tu caso de uso?

Arquitecturas de Modelos



Decoder-Only

Genera texto de izquierda a derecha, predice el siguiente token.

Modelos:

GPT-4, GPT-4o, Claude 3.x, Llama 3, Mistral, Gemini

Casos de uso:

- Generación de texto libre
- Chatbots y asistentes
- Código (Copilot, CodeLlama)
- Análisis y razonamiento

*Causal
(solo ve hacia atrás)*



Encoder-Only

Comprende el contexto completo (bidireccional). No genera texto.

Modelos:

BERT, RoBERTa, DistilBERT, XLM-R, mBERT

Casos de uso:

- Clasificación de texto
- Análisis de sentimiento
- Embeddings semánticos
- Búsqueda semántica (RAG)

*Bidireccional
(contexto completo)*



Encoder-Decoder

Combina comprensión (encoder) con generación (decoder).

Modelos:

T5, BART, mT5, Pegasus, MarianMT

Casos de uso:

- Traducción automática
- Resumen de documentos
- Q&A extractivo
- Corrección gramatical

*Bidireccional + Causal
(cross-attention)*

Cloud vs On-Premise | Casos LATAM

Criterio	 Cloud API	 On-Premise / Local
Costo por uso	Pay-per-token (predecible)	Infraestructura propia (upfront)
Privacidad	Datos van al proveedor	Datos 100% en tus servidores 
Calidad	Los mejores modelos (GPT-4o)	Depende del modelo descargado
Escalabilidad	Automática e instantánea	Limitada por hardware propio
Compliance	Requiere DPA/acuerdos	Control total sobre datos 
Latencia	10-60ms red + procesamiento	Local: <10ms en GPU dedicada
Mantenimiento	Ninguno (managed)	Actualización de modelos propia

Regla práctica para LATAM:

- Sector financiero/salud/gobierno → On-premise o Llama local (datos sensibles, GDPR/LGPD)
- Startups y MVPs → Cloud API (GPT-4o mini o Gemini Flash = menor costo de arranque)
- Empresas medianas con volumen alto → Modelo híbrido: local para datos sensibles + cloud para el resto


TEMA 3

Consideraciones de Costos

De la prueba de concepto a producción: cómo evitar sorpresas en la factura

Comparativa de Proveedores y Costos

Proveedor	Modelo	\$/1M tokens in	\$/1M tokens out	Fortaleza	Para LATAM
OpenAI	GPT-4o	\$2.50	\$10.00	Calidad máxima	Azure LATAM
OpenAI	GPT-4o mini	\$0.15	\$0.60	Mejor costo/calidad	Ideal MVPs
Anthropic	Claude 3.5 Haiku	\$0.80	\$4.00	Instrucciones complejas	Procesos regulados
Google	Gemini 1.5 Flash	\$0.075	\$0.30	Más económico	GCP Colombia/Mx
Local	Llama 3.2:3B	\$0.00	\$0.00	Privacidad total	Datos sensibles 



 Insight clave:

Gemini Flash vs GPT-4o:

97% de ahorro en tokens.

Ollama local:

Costo = \$0 por token
(solo electricidad + hardware)

ROI, Evaluación de Proveedores y Riesgo

Framework de TCO (Total Cost of Ownership)

Costos directos: Tokens, API calls, suscripciones

Infraestructura: GPU, servidores, cloud compute

Desarrollo: Ingeniería, prompt engineering

Operación: Monitoreo, mantenimiento, soporte

Datos: Preparación, storage, labeling

Compliance: Auditorías, DPA, certificaciones

Riesgos Críticos de Adopción

Vendor Lock-in

Migrar de GPT-4 a Claude puede requerir re-prompt. Usar LangChain como abstracción.

Hallucinations

Los LLM generan texto incorrecto con confianza. Implementar validaciones y RAG.

Costo runaway

Un loop de agentes puede generar millones de tokens en minutos. Siempre: rate limits.

Privacidad LGPD

Brasil LGPD, Colombia Ley 1581. Revisar DPA de cada proveedor antes de usar.



Demo en Vivo

1

LLM Local con Ollama

Ejecutar Llama 3.2 en tu laptop sin internet ni costo por token.

```
$ python  
examples/ollama_demo/demo_local.py
```

2

Streaming de Respuestas

Ver cómo los tokens llegan en tiempo real mejorando la UX.

```
$ python  
examples/ollama_demo/demo_streaming.py
```

3

API FastAPI + Ollama

Exponer el LLM como servicio REST profesional con Swagger UI.

```
$ make run-api →  
http://localhost:8000/docs
```


✓ Prerrequisitos: Ollama instalado + modelo descargado (ollama pull llama3.2:3b) + pip install -r requirements.txt

Proyecto Final — Entregables y Criterios de Evaluación

Entregables del Proyecto

1. Repositorio GitHub estructurado
 - README, requirements.txt, Makefile
 - Código documentado (docstrings)
2. API FastAPI funcional
 - Mínimo 3 endpoints documentados
 - Health check + Swagger UI
3. Integración LLM real
 - Al menos 1 proveedor (Ollama o API)
 - Streaming implementado
4. Análisis de costos
 - Comparativa de al menos 3 proveedores
 - Justificación de la selección

Criterios de Evaluación



Resumen y Próximos Pasos

✓ Aprendimos Hoy

- Transformers (2017) son la base de todos los LLM modernos
- 3 arquitecturas: decoder-only (GPT), encoder-only (BERT), encoder-decoder (T5)
- Cloud vs local: trade-off costo/privacidad/calidad
- Costos varían hasta 97% entre proveedores
- Ollama permite LLM local gratis en tu laptop

🚀 Para esta Semana

1. Instalar Ollama y ejecutar demo_local.py
2. Explorar la API FastAPI en /docs
3. Ejecutar la calculadora de costos con tu caso de uso real
4. Crear tu repositorio en GitHub con la estructura del Makefile
5. Identificar un caso de uso LATAM de tu sector para el proyecto