



# Programa Certified AI-LLM Integration Engineer

Curso de Fundamentos de LLMs y APIs

[www.bsginstitute.com](http://www.bsginstitute.com)

## Andrés Felipe Rojas Parra

- Ingeniero electrónico con mas de 23 años de experiencia
- PGP Artificial Intelligence & Machine Learning at Texas University – Austin, TX
- Master en Inteligencia Artificial y Big Data – IEBSchool
- Estudiante de PGP en Cloud Computing at Texas University - Austin, TX
- Texas Executive Education Program – McCombs School of Business – Decision Science and AI Immersion Program
- Especialización en MLOps de la Universidad de Duke



[arojaspa@outlook.com](mailto:arojaspa@outlook.com)



@arojaspa



<https://www.linkedin.com/in/arojaspa/>



+573005906373



Capítulo 3 — Proyecto Integrador

# Sesión 4

## SESIÓN FINAL

Noticias Financieras · Inteligencia Competitiva · Presentación del Proyecto

**1** Análisis Noticias  
Financieras — Local

**2** Inteligencia  
Competitiva — Azure

**3** Presentación  
Proyecto Final

# Agenda — Sesión 4 Final

0

1

## Noticias Financieras — Ollama Local

*~45 min*

- Pipeline: limpieza → heurísticas → LLM → resultado
- Batch processing con `asyncio.gather()`
- Streaming SSE token a token
- Demo: análisis PFBCOLO en BVC

0

2

## Inteligencia Competitiva — Azure

*~45 min*

- Pipeline estratégico con GPT-4o
- JSON mode para reporte estructurado
- Análisis de competidores LATAM
- Demo: Nequi vs Daviplata vs Movii

0

3

## Presentación del Proyecto Final

*~90 min*

- 15 min por equipo + 5 Q&A
- Rúbrica: 5 criterios, 100 puntos
- Retroalimentación del instructor
- Cierre del curso y certificación

T E M A 1

# Análisis de Noticias Financieras — Local

*Pipeline completo / Batch processing / Streaming SSE / BVC LATAM / 100% local*

# Tema 1 — Pipeline de Análisis de Noticias Financieras (FastAPI + Ollama)

## Caso de uso

Fondo de inversion colombiano analiza 100+ noticias/dia para su comite. Datos financieros NUNCA salen.

---

## 4 pasos del pipeline

1. Limpieza de texto
2. Heurísticas (keywords)
3. LLM analisis narrativo
4. Respuesta estructurada

---

## Nuevos conceptos S4

Batch: `asyncio.gather()` para paralelismo.

Streaming: SSE token a token.

## Pipeline de Analisis de Noticias Financieras — Arquitectura completa



# Batch Processing y Streaming SSE — Conceptos clave de la Sesión 4

## Batch: asyncio.gather() — Paralelo

```
# Procesar 20 noticias en paralelo
async def analyze_batch(request):
    loop = asyncio.get_event_loop()
    # run_in_executor: no bloquea FastAPI
    tasks = [
        loop.run_in_executor(
            None, self.analyze, article
        )
        for article in request.articles
    ]
    # Ejecuta todas en paralelo
    results = await asyncio.gather(*tasks)
    return BatchAnalysisResponse(
        bullish_count=sum(r.sentiment > 0.2),
        top_signals=sorted(all_signals)[:5]
    )
```

## Streaming SSE — Tokens en tiempo real

```
@app.get("/news/stream/{id}")
async def stream_analysis(article_id: str):
    async def generate():
        stream = ollama.chat(
            model="llama3.2:3b",
            messages=[...],
            stream=True # ← clave
        )
        for chunk in stream:
            token = chunk["message"]["content"]
            # Enviar token al cliente
            yield f"data: {token}\n\n"
        yield "data: [DONE]\n\n"

    return StreamingResponse(
        generate(),
        media_type="text/event-stream"
    )
```

T E M A 2

# Inteligencia Competitiva — Azure AI Foundry

*Pipeline estratégico | GPT-4o | JSON mode | Mercados LATAM | SLA 99.9%*



# Tema 2 — Pipeline de Inteligencia Competitiva (Azure AI Foundry + GPT-4o)

## Caso de uso

Empresa LATAM analiza posicion competitiva, tendencias de mercado y oportunidades estrategicas.

---

## Por que GPT-4o aqui?

Comprension profunda de contexto empresarial y mercados LATAM. Llama 3.2:3b no tiene suficiente contexto estrategico.

---

## JSON mode garantiza


Reporte estructurado sin errores de parseo. `response_format: json_object`

---

## Output del reporte

`competitive_position`  
(lider/retador/seguidor/nicho)  
`competitor_insights` (strengths, weaknesses)

## Pipeline Inteligencia Competitiva — Azure AI Foundry + GPT-4o



# Demo — Nequi vs Daviplata vs Movii vs Rappipay (Colombia Fintech)

GET <http://localhost:8006/intel/demo> → Análisis sin autenticación, listo para mostrar en clase

## Request (input)

```
# Empresa analizada: Nequi
# Competidores: Daviplata, Movii, Rappipay
# Foco: product_features, pricing,
#       digital_adoption, regulatory
# Contexto: mercado billeteras digitales
#           Colombia creció 45% en 2024
#           18M usuarios activos
#           Sandbox Banrep habilitado
```

```
curl http://localhost:8006/intel/demo
```

## Response (fragmento)

```
{
  "competitive_position": "retador",
  "market_trend": "creciente",
  "competitor_insights": [
    {
      "competitor": "Daviplata",
      "strengths": ["Red bancaria Davivienda", "17M usuarios"],
      "weaknesses": ["UX inferior", "Credito limitado"],
      "key_differentiator": "Respaldo bancario"
    }
  ],
  "opportunities": [{
    "type": "expansion_geografica",
    "description": "Zonas rurales sin bancarizar",
    "potential": "alto",
    "timeline": "mediano plazo"
  }],
  "strategic_recommendations": [
    "Acelerar credito digital rural",
    "Alianza con operadores moviles"
  ]
}
```

## TEMA 3

# Presentación Final del Proyecto

*15 min por equipo | 5 Q&A | Rúbrica 100 pts | Demo en vivo | Certificación*

# Rúbrica de Evaluación — Proyecto Final (100 puntos)

## Rubrica de Evaluacion — Proyecto Final (100 puntos)

25 pts

25 pts

20 pts

15 pts

15 pts

### API Funcional

- ☐ 3+ endpoints
- ☐ Swagger UI
- ☐ Manejo errores
- ☐ Health check

### Integracion LLM

- ☐ LLM conectado
- ☐ Prompt diseñado
- ☐ Parseo output
- ☐ Fallback

### Seguridad

- ☐ Auth JWT/API Key
- ☐ HTTP 401/403
- ☐ Rate limit o cifrado
- ☐ Audit log

### Documentacion

- ☐ README completo
- ☐ ADR-001
- ☐ Analisis costos
- ☐ Makefile

### Presentacion

- ☐ Demo en vivo
- ☐ Valor negocio
- ☐ QandA fluido
- ☐ 15 min limite

Nota mínima para aprobar: 60/100 | Bonificacion: +5 pts (tests + Docker + Streaming)

# Estructura de la Presentación — 15 minutos por equipo

2 min

## El Problema

¿Qué problema resuelve tu proyecto? ¿Para quién?  
¿En qué sector LATAM?

3 min

## Costos y ROI

TCO del proyecto: infra + LLM API + desarrollo.  
¿Cuánto ahorra al cliente?

3 min

## La Arquitectura

Diagrama C4, stack tecnológico, decisiones (ADR) y por qué elegiste Ollama o Azure.

2 min

## Conclusiones

¿Qué aprendiste? ¿Qué mejorarías? ¿Cómo lo llevarías a producción?

5 min

## Demo en Vivo

Mostrar los endpoints funcionando en Swagger UI.  
Un caso real de tu proyecto.

5 min

## Q&A

Preguntas del instructor y compañeros. Explicar decisiones técnicas.

# Mapa de Aprendizaje — Lo que dominaste en 4 sesiones

## Mapa de Aprendizaje — Fundamentos de Arquitectura LLM (4 Sesiones)



### Stack Tecnológico Dominado al finalizar el curso

Python 3.12

FastAPI

Pydantic

Ollama

Azure AI Foundry

GPT-4o

JWT + RBAC

AES-256

Docker

Kubernetes

HPA

Prometheus + Grafana

# Felicitaciones — Completaste el Curso

## Lo que construiste

- Sistema de riesgo crediticio (Sesión 1)
- Detección de fraude bancario (Sesión 2)
- Triage médico con JWT + seguridad (Sesión 3)
- Proyecto integrador propio (Sesión 4)
- 4 APIs FastAPI con LLM integrado
- Repositorio GitHub profesional con ADR

## Tu Proyecto Final

- API funcional con 3+ endpoints
- LLM integrado (Ollama o Azure AI Foundry)
- Seguridad: autenticación + al menos 1 control
- Documentación: README + ADR + Makefile
- Demo en vivo presentada al grupo
- Análisis de costos y ROI calculado

¡El aprendizaje continúa! Siguiente paso: **Curso Implementando tu Primer Agente IA**

[github.com/arojaspa76/Repo-AI-LLM-Solutions-Architect-Project](https://github.com/arojaspa76/Repo-AI-LLM-Solutions-Architect-Project)